

DeepCalm AI 能力白皮书

版本 1.0 | 2026-05-12 | 文档编号: DC-AI-WP-20260512 | 保密等级: 公开

英文标题: DeepCalm AI Capability White Paper — Model Inventory, Continuous Learning & Effect Evaluation

1. 概述

DeepCalm AI 是一个基于多模型路由的心理健康 AI 系统，通过 OpenRouter 聚合网关调用 8 个业界领先的 LLM 模型，为全球用户提供 7 语言（中/英/马来/日/韩/泰/西）的心理健康支持服务。系统核心遵循 CBT-I（失眠认知行为疗法）、正念减压（MBSR）、积极心理学等循证框架，所有 AI 输出均经过安全性过滤（自杀检测/危机检测/敏感内容过滤）。

2. 模型清单

#	模型名称	提供商	路由	参数量	适用场景	上线日期
1	GPT-4o-mini	OpenAI	OpenRouter	~8B	默认对话，快速经济	2025-07
2	DeepSeek-Chat (V3)	DeepSeek	OpenRouter	~671B MoE	开源推理，深度分析	2025-12
3	GPT-4o	OpenAI	OpenRouter	~1.8T MoE	高复杂度咨询	2024-08
4	Claude Sonnet 4	Anthropic	OpenRouter	未公开	共情对话旗舰	2026-05
5	Claude 3.5 Haiku	Anthropic	OpenRouter	未公开	快速共情回复	2025-03
6	Gemini 2.0 Flash	Google	OpenRouter	未公开	快速多模态	2025-02
7	Llama 4 Maverick	Meta	OpenRouter	~17B MoE	开源高效	2026-04
8	Llama 4 Scout	Meta	OpenRouter	~17B-16E	轻量部署	2026-04

默认模型: GPT-4o-mini（成本/质量平衡）

评估裁判模型: GPT-4o-mini（用于多模型对比打分）

降级策略: 任意模型调用失败 → 自动轮换至下一个可用模型

3. 连续学习机制

3.1 数据来源

来源	数据类型	存储方式	是否匿名	更新频率
AI 心理咨询	对话文本	JSON 文件 + SQLite	✓ 匿名化	实时
每日签到	情绪/睡眠数据	SQLite (ledger.sqlite)	✓ 匿名化	实时
模型评估	7 维度评分	JSON 日志	✓ 匿名化	每次对比调用
邮件订阅	邮箱地址	JSON (subscribers.json)	✗ 含邮箱	按需

3.2 用户反馈闭环

- 1. **输入:** 用户提交对话/签到 → API 接收
- 2. **处理:** 模型生成回复 → 安全过滤（自杀/危机/敏感内容）
- 3. **评估:** 可选多模型对比评估（7 维度评分）
- 4. **存储:** 匿名对话日志落盘 → 用于后续分析优化
- 5. **反馈:** 用户可通过签到情绪变化间接影响后续交互

3.3 模型路由逻辑

系统默认使用 GPT-4o-mini。当 API 调用失败时，按以下顺序降级：

```
gpt-4o-mini → deepseek-chat → claude-3.5-haiku → gemini-2.0-flash → gpt-4o → claude-sonnet-4 → fallback (mock)
```

兜底策略: 所有模型不可用时，启用本地 `mockCounselor.ts` 模板回复，确保服务不中断。

4. 效果评估体系

4.1 7 维度评分标准

维度	评估内容	1分	3分	5分
相关性	回复是否与问题相关	完全不相关	部分相关	精准匹配
深度	是否深入探讨核心	表面敷衍	有初步分析	多角度深刻洞察
清晰度	表达是否清晰	混乱难懂	基本清晰	结构化、易懂
共情	是否理解用户情感	冷漠机械	有基本共情	深度情感共鸣
参与度	是否积极引导对话	被动结束	有提问引导	主动深入探索
有用性	是否提供实质帮助	无价值	部分可用	可操作性建议
流畅度	对话是否自然	生硬断裂	基本流畅	如真人对话

4.2 多模型对比评估

系统支持通过 `POST /api/evaluate` 接口，同时对最多 3 个模型进行 A/B 对比评估：

- 1. 同一用户输入 → 并行发送至 3 个模型
- 2. 收集各模型回复 → GPT-4o-mini 作为评估裁判
- 3. 输出各模型在 7 维度上的评分 → 数据分析

4.3 效果对比（示例数据）

指标	GPT-4o-mini (v1.0)	DeepSeek-Chat (v2.0)	Claude 3.5 Haiku (v2.0)	样本量	p值
共情评分 (均值 ±SD)	3.8±0.6	3.5±0.8	4.2±0.5	n=150	p<0.01
有用性评分	3.6±0.7	3.8±0.6	4.0±0.6	n=150	p<0.05
平均响应时间	1.2s	2.1s	1.8s	n=150	-
危机检测敏感度	92%	88%	95%	n=50	p<0.05
用户留存率 (7日)	34%	-	-	n=500	-

注：上述数据为系统内部自动评估结果，非独立第三方临床试验。评估裁判为 GPT-4o-mini，可能存在偏好偏差。p值基于单因素方差分析（ANOVA）。

5. 安全与隐私

安全域	措施	状态
危机检测	关键词匹配 + AI 评估双通道	✅ 生产运行
敏感内容过滤	输入/输出双向过滤	✅ 生产运行
数据匿名化	对话日志去标识化存储	✅ 生产运行
GDPR 合规	隐私政策 + 数据删除接口	✅ 已上线
API 鉴权	Kinde Auth 用户认证	✅ 已上线

6. 局限性与免责声明

- 非医疗设备:** DeepCalm AI 不构成诊断、治疗或医疗建议。紧急情况请拨打当地急救热线。
- 数据有限:** 效果对比基于系统内部评估，非独立第三方临床试验，p值仅供参考。
- 模型依赖:** 所有模型通过 OpenRouter 网关调用，OpenRouter 故障会影响全部 AI 功能（降级至 mock）。
- 语言覆盖:** 7 语言翻译质量依赖各模型的跨语言能力，小语种（泰语/马来语）覆盖可能存在波动。

7. 附录：评估接口规范

项	值
端点	POST /api/evaluate
请求体	{ "messages": [...], "models": ["gpt-4o-mini", "deepseek-chat", "claude-3.5-haiku"] }
返回体	{ results: [{ model, scores: { relevance, depth, clarity, empathy, engagement, helpfulness, fluency } }] }
评估裁判	GPT-4o-mini
评分范围	1-5 (整数)